



**Politecnico
di Torino**

Politecnico di Torino

Laurea Magistrale in Ingegneria Matematica

**Studio avanzato dei meccanismi epigenetici
nello sviluppo di neoplasie**

Elisabetta Roviera

Analisi Esplorativa Intra- e Inter-Dataset della Metilazione del DNA

Introduzione L'obiettivo biologico alla base di questo lavoro di tesi è valutare se specifiche alterazioni della metilazione del DNA, presenti nel tessuto normale o istologicamente sano in prossimità del tumore, possano contribuire o precedere la trasformazione neoplastica. In tale contesto, l'esplorazione dei dati rappresenta un passaggio essenziale per valutare la qualità, la struttura interna e la comparabilità dei dataset utilizzati.

Sono state quindi condotte due tipologie di analisi:

- un'analisi **intra-dataset**, volta a caratterizzare indipendentemente ciascuna coorte lungo l'asse Normal-Adjacent-Tumor;
- un'analisi **inter-dataset**, finalizzata a valutare la riproducibilità delle alterazioni osservate tra studi diversi.

Armonizzazione dei Dataset Prima dell'esplorazione, i tre dataset GEO selezionati ([GSE69914](#), [GSE225845](#), [GSE287331](#)) sono stati ricostruiti in un formato omogeneo e direttamente comparabile. Per ciascun dataset sono stati generati:

- una matrice di metilazione ($\text{campioni} \times \text{CpG}$) contenente i valori di β in formato `float32`;
- una tabella fenotipica strutturata e completa, contenente tutti i metadati disponibili per ogni campione.

Sono stati inoltre rimossi i campioni non confrontabili tra dataset, come i BRCA1-mutated in [GSE69914](#) e le categorie OQ/CUB in [GSE287331](#).

Analisi Intra-Dataset L'esplorazione indipendente delle tre coorti mette in evidenza alcuni pattern ricorrenti e differenze specifiche fra i dataset. Di seguito si riportano i principali risultati in forma sintetica:

- **Qualità dei dati.** I dataset [GSE69914](#) e [GSE225845](#) non presentano valori mancanti; [GSE287331](#) mostra una quantità minima di NaN, corretti mediante filtraggio e imputazione.
- **Pattern globali di metilazione.** In tutte le coorti è presente il classico profilo bimodale delle piattaforme Illumina. I campioni Tumor mostrano un appiattimento del picco ad alta metilazione e una maggiore eterogeneità globale; i campioni Adjacent evidenziano un lieve spostamento verso il profilo tumorale, suggerendo un *early drift* compatibile con fenomeni di *field cancerization*.
- **Alterazioni locali (CpG-specifiche).** L'analisi degli outlier CpG e delle distribuzioni di $\Delta\beta$ mostra in tutti i dataset una predominanza di loci ipometilati nei Tumor. I campioni Adjacent presentano deviazioni più contenute ma sistematiche, indicative di alterazioni iniziali o parziali.
- **Struttura della variabilità e delle correlazioni.** La varianza CpG-wise è minima e quasi sovrapposta tra Normal e Adjacent nei dataset [GSE69914](#) e [GSE225845](#); i campioni Tumor mostrano un aumento della variabilità. Nel dataset [GSE287331](#) la distinzione fra le tre classi risulta più marcata.
- **Embeddings a bassa dimensionalità.** PCA, t-SNE e UMAP mostrano una sostanziale sovrapposizione tra Normal e Adjacent nelle coorti [GSE69914](#) e [GSE225845](#). Nel dataset [GSE287331](#) (non normalizzato con BMIQ) emerge invece una chiara separazione tra Normal, Adjacent e Tumor, evidenziando un segnale biologico più forte e definito.

- **Bias di tipo I/II (solo GSE287331).** L'analisi ha evidenziato un marcato disallineamento tra le sonde Type I e Type II, indicativo dell'assenza di correzione del bias di design nel dataset originale. Ho quindi applicato il metodo BMIQ per correggere tale bias: la normalizzazione riduce parzialmente la discrepanza tra le due famiglie di sonde, ma tende anche ad appiattire, seppure leggermente, la separazione biologica tra i gruppi. Per questo motivo, le successive analisi verranno condotte sulla versione non-BMIQ, che preserva più fedelmente la struttura intrinseca dei dati.

Analisi Inter-Dataset L'analisi inter-dataset è stata condotta considerando le sonde condivise fra le tre piattaforme (circa 326 000 CpG). Il confronto delle distribuzioni di $\Delta\beta$, della varianza e delle proiezioni multi-dimensionali mostra una buona coerenza dei pattern di drift Normal $\rightarrow$ Adjacent tra i dataset, pur con differenze di intensità e sensibilità tecnica. Le analisi combinate PCA/t-SNE evidenziano un forte effetto di piattaforma e di studio, tale da rendere impossibile un'unificazione diretta dei dataset senza accesso ai dati grezzi (IDAT) e senza una pipeline di normalizzazione completamente condivisa.

Conclusioni L'analisi esplorativa, condotta sia a livello intra-dataset sia inter-dataset, evidenzia che:

- esistono alterazioni di metilazione riproducibili lungo l'asse Normal-Adjacent, più nette nel dataset GSE287331;
- la forza del segnale biologico varia tra le coorti, risultando più marcata e meglio definita nel dataset GSE287331;
- la struttura globale dei dati e il batch effect impediscono la fusione diretta delle coorti, rendendo necessaria una pipeline di pre-processing avanzata per le analisi successive.

In base a queste evidenze, il dataset GSE287331 verrà utilizzato come **coorte di discovery** per l'identificazione delle alterazioni epigenetiche iniziali, mentre i dataset GSE69914 e GSE225845 saranno impiegati come **coorti di validazione** per verificarne la robustezza e la riproducibilità.

Risorse Tutto il materiale utilizzato per questa tesi, inclusi notebook, report, script e documentazione, è disponibile nella repository:

github.com/elisabettaroviera/THESIS

I report completi sono disponibili ai seguenti link:

00 -- Report Dataset Construction, Storage and Metadata Acquisition (PDF)
 01 -- Report Data Exploration & Visualization (PDF)

Di seguito si riportano tutti i notebook sviluppati e utilizzati.

- 00-dataset-preparation-GSE69914.ipynb – Ingestion e preparazione della matrice β di GSE69914.
- 00-dataset-metadata-GSE69914.ipynb – Estrazione e armonizzazione dei metadati di GSE69914.
- 00-dataset-preparation-GSE225845.ipynb – Ingestion streaming e costruzione della matrice β di GSE225845.
- 00-dataset-metadata-GSE225845.ipynb – Estrazione dei metadati di GSE225845.
- 00-dataset-preparation-GSE287331.ipynb – Ingestion e costruzione della matrice β di GSE287331.
- 00-dataset-metadata-GSE287331.ipynb – Estrazione dei metadati di GSE287331.
- 00-uniformation-of-the-gse.ipynb – Armonizzazione delle matrici β e delle tabelle fenotipiche tra i tre dataset.
- 01-data-exploration-visualization-GSE69914.ipynb – Analisi esplorativa di GSE69914 (distribuzioni, outlier, varianza, embedding).
- 01-data-exploration-visualization-GSE225845.ipynb – Analisi esplorativa di GSE225845 ($\Delta\beta$, outlier, embedding non lineari, network proxy).
- 01-data-exploration-visualization-GSE287331.ipynb – Analisi esplorativa di GSE287331 (separazione Normal-Adjacent-Tumor).
- 01-data-explorationvisualization-inter-analysis.ipynb – Confronto inter-dataset (CpG condivisi, $\Delta\beta$ concordanza, PCA/t-SNE combinati).
- 01-correction-bias-type-i-vs-type-ii.ipynb – Diagnostica del bias Type I/II e applicazione BMIQ nel dataset GSE287331.